



北京大学
PEKING UNIVERSITY

智能硬件体系结构

第十三讲：存算一体与光计算

主讲：陶耀宇

2026年春季

- 课程作业情况

- 作业时间

第二次作业时间：5.11-5.25

第三次作业时间：5.28-6.13

- 第1次lab时间：4月13日-5月28日 **(因CLAB故障延期)**
- 第2次lab时间：5月23日-6月18日 **(因CLAB故障延期，已适当简化)**
- 文献调研与报告（截止日期为6月15日）（提交PPT+录视频）

主讲：陶耀宇、李萌

- 自行选择器件 (IEDM等)、电路 (ISSCC、VLSI等) 或架构 (MICRO、ISCA等) 方面的论文, 或Nature/Science系列相关论文, 进行3-5篇文献阅读
- 占总成绩20%, 分组 (2-3人一组) 深入论文技术细节, 做10分钟汇报

AI加速器芯片

- 传统AI加速器: Fused-layer cnn accelerators、Eyeries, Google TPU等
- 新兴AI加速器 (大模型Transformer、Neural ODE、MANN/DNC、PINN等)

GPGPU芯片

- 流式多处理器 (Multithreaded Streaming Multiprocessors, CUDA的来源)

FPGA芯片等 (可编程逻辑块、可编程路由等)

安全与通信领域处理器芯片

- 各类密钥编码 (AES、RSA)、视频编码 (MPEG等)、通信编码 (LDPC、Polar等)

传统CPU芯片

- 优化Branch Predictor、Load-Store、缓存预读取、众核缓存一致性等

新兴智能计算芯片

- 存算一体/感存算一体、量子计算、生物信息处理、高维NoC、区块链
- 基于后摩尔非CMOS器件的架构 (模拟计算架构、动力学计算架构等)

目录

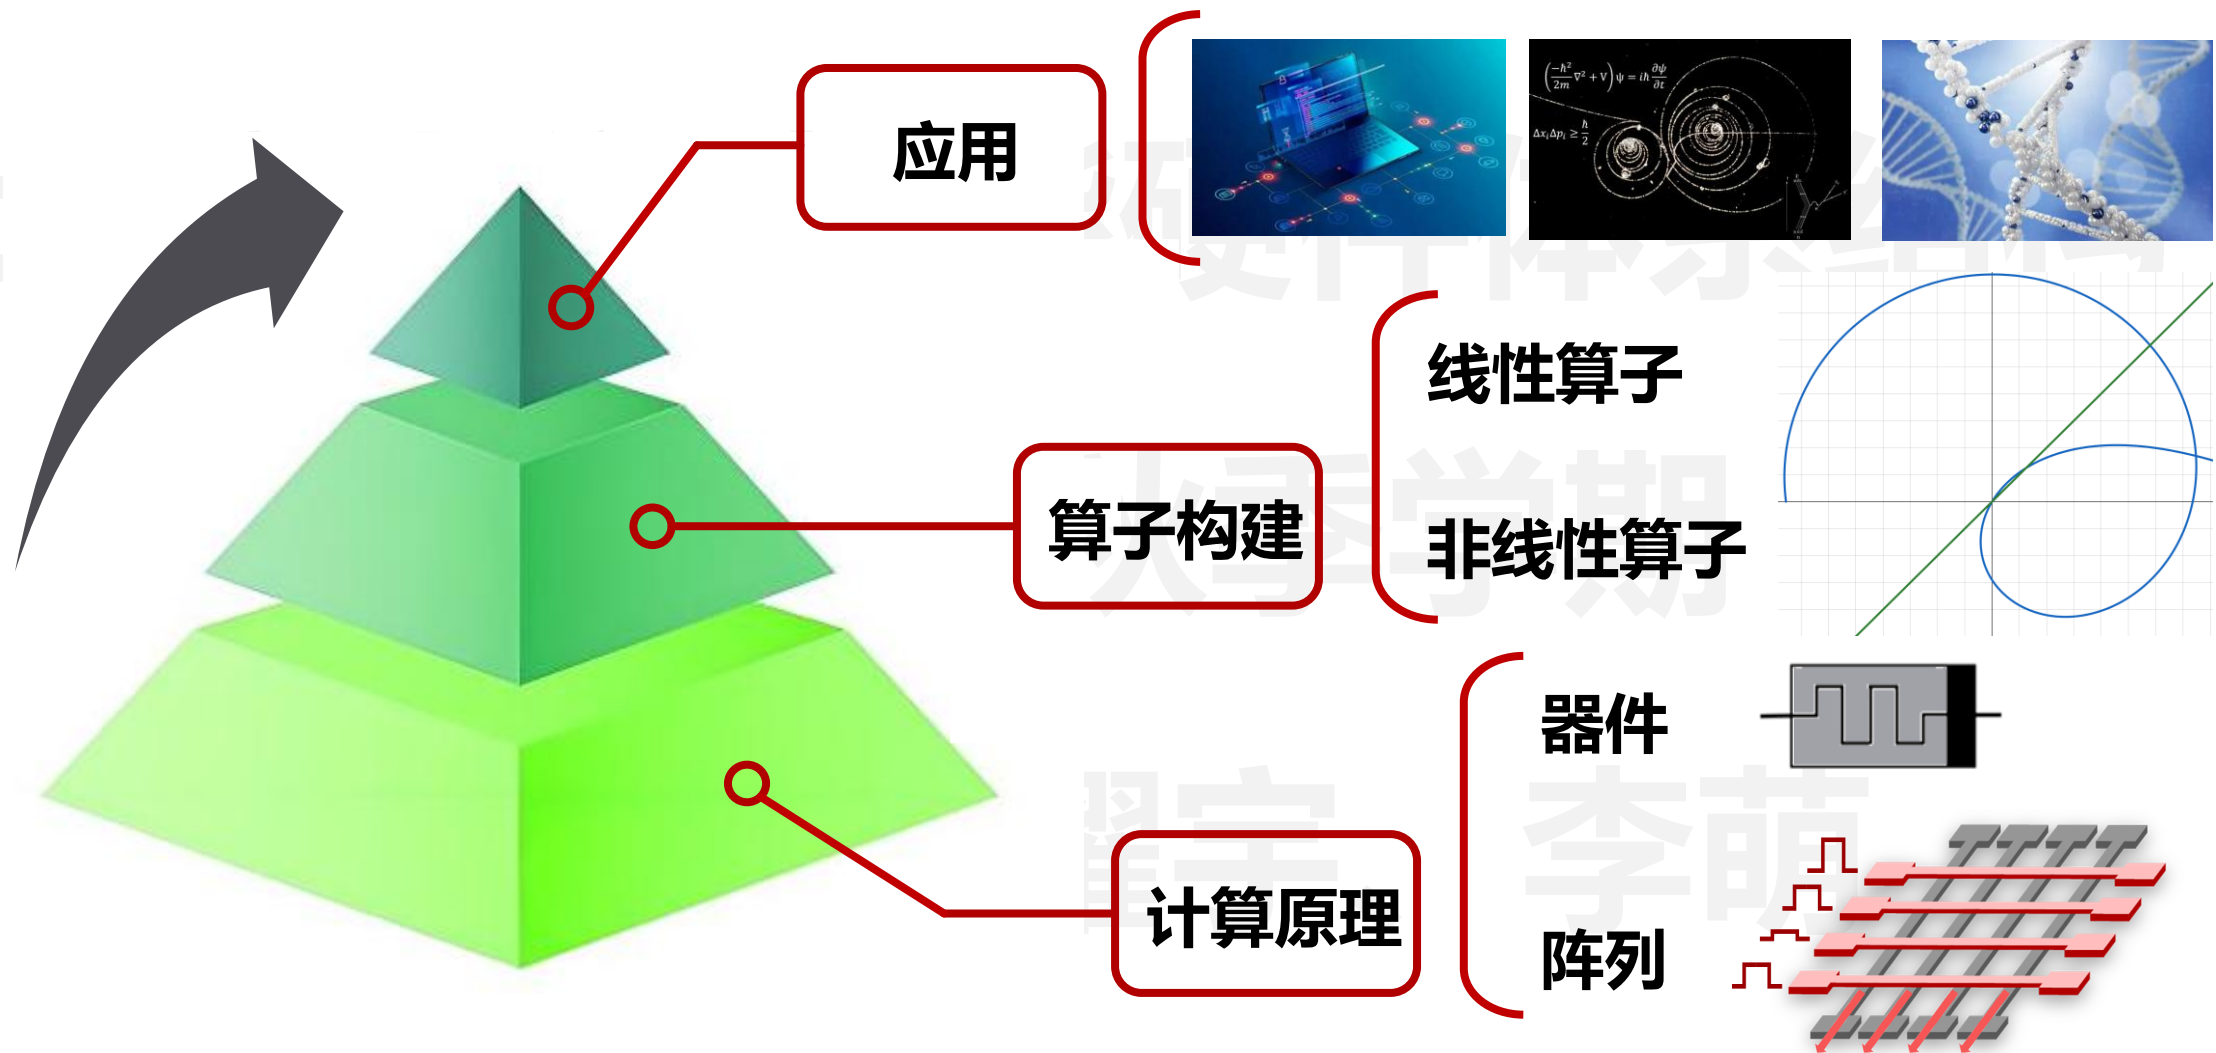
CONTENTS



- 01. 存算一体芯片发展概述
- 02. 存算一体芯片算子拓展
- 03. AI大模型存算一体加速
- 04. 存算一体任务编译部署

存算一体化算子拓展

- 从当前矩阵乘法、卷积等少量线性计算迈向多种非线性算子



- 基于阵列的线性算子实现方法

□ 线性算子

1. 矩阵向量乘法
2. 矩阵矩阵乘法
3. 矩阵矩阵向量乘法
4. 傅里叶变换

.....

□ 非线性算子

1. 汉明距离 (查找比对)
2. 欧氏距离
3. 排序
4. 正态分布生成
5. 非线性初等函数

.....


叠加原理: $A(x + y) = A(x) + A(y)$

齐次原理: $A(\alpha x) = \alpha A(x)$

- 矩阵向量乘法与卷积

□ 矩阵向量乘法


$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}^T \begin{bmatrix} A_{11} & A_{12} & A_{13} \\ A_{21} & A_{22} & A_{23} \\ A_{31} & A_{32} & A_{33} \end{bmatrix} = \begin{bmatrix} A_{11}x_1 + A_{21}x_2 + A_{31}x_3 \\ A_{12}x_1 + A_{22}x_2 + A_{32}x_3 \\ A_{13}x_1 + A_{23}x_2 + A_{33}x_3 \end{bmatrix}^T$$



$$y_j = \sum_i A_{i,j} * x_i$$

□ 卷积：神经网络基本算子

$$y_{i,j} = \sum_{u,v} w_{u,v} * x_{i+u,j+v}$$




Dumoulin, Vincent, and Francesco Visin. arXiv 2016.

存算一体化典型算子 – 矩阵矩阵乘法

• 矩阵矩阵乘法

□ 构建方法:

- 时域 → 频域
- 在频域进行计算



Wang, Cong, et al. Nature Nanotechnology 2021.

- 模拟权重
- 速度快, 精度低
- 额外开销

□ 傅里叶变换

$$F(\omega) = \int_{-\infty}^{+\infty} f(t)e^{-i\omega t} dt$$

□ 离散傅里叶变换 $\sim O(N^2)$

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-i\frac{2\pi}{N}kn} \quad 0 \leq k < N$$



□ 忆阻器存算一体实现 $\sim O(N)$

$$\begin{bmatrix} X_0 \\ X_1 \\ \dots \\ X_{N-1} \end{bmatrix} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & \omega & \dots & \omega^{N-1} \\ \dots & \dots & \dots & \dots \\ 1 & \omega^{N-1} & \dots & \omega^{(N-1)^2} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_{N-1} \end{bmatrix}$$

欧拉公式 $\omega = e^{-i\frac{2\pi}{N}} = \cos \frac{2\pi}{N} - i \sin \frac{2\pi}{N}$

□ 快速傅里叶变换 $\sim O(N \log N)$


$$\begin{cases} X[k] = F_{\text{even}}(k) + e^{-i\frac{2\pi}{N}k} F_{\text{odd}}(k) & 0 \leq k < \frac{N}{2} \\ X\left[k + \frac{N}{2}\right] = F_{\text{even}}(k) - e^{-i\frac{2\pi}{N}k} F_{\text{odd}}(k) & 0 \leq k < \frac{N}{2} \end{cases}$$

构建方法

$$\begin{bmatrix} X_0 \\ X_1 \\ \dots \\ X_{N-1} \end{bmatrix} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & \omega & \dots & \omega^{N-1} \\ \dots & \dots & \dots & \dots \\ 1 & \omega^{N-1} & \dots & \omega^{(N-1)^2} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_{N-1} \end{bmatrix}$$

$$\omega = e^{-i\frac{2\pi}{N}} = \cos \frac{2\pi}{N} - i \sin \frac{2\pi}{N}$$

映射方案1




- 模拟计算
- 长度限制
- 阵列冗余

Zhao, Han, et al. Nature Communications 2023.

$$\begin{bmatrix} X_{real} \\ X_{img} \end{bmatrix} = \begin{bmatrix} Re(W) & -Im(W) \\ Im(W) & Re(W) \end{bmatrix} \begin{bmatrix} x_{real} \\ x_{img} \end{bmatrix}$$

映射方案2



- 模拟计算
- 频繁写入
- 多周期输入

$$X[k] = \sum_{n=0}^{N-1} x[n] \left(\cos \frac{2\pi}{N} kn - i \sin \frac{2\pi}{N} kn \right)$$

- 基于阵列的非线性算子实现方法

□ 线性算子

1. 矩阵向量乘法
2. 矩阵矩阵乘法
3. 矩阵矩阵向量乘法
4. 傅里叶变换

.....

□ 非线性算子

1. 汉明距离 (查找比对)
2. 欧氏距离
3. 排序
4. 正态分布生成
5. 非线性初等函数

.....

叠加原理: $A(x + y) = A(x) + A(y)$

齐次原理: $A(\alpha x) = \alpha A(x)$

□ 闵可夫斯基距离 (L-P范数)

$$L_p = \|x - w\|_p = \left(\sum_i |x_i - w_i|^p \right)^{\frac{1}{p}}$$

难点：指数的计算

难点1：异或的计算

难点2：求和的计算

□ 曼哈顿距离 (p=1)

$$L_1 = \|x - w\|_1 = \sum_i |x_i - w_i|$$

□ 汉明距离

■ 01串: $L_d = L_1 = \sum_i |x_i - w_i|$

■ 其他情况: $L_d = \sum_i \text{xor}(x_i, w_i)$

□ 欧氏距离 (p=2)

$$L_2 = \|x - w\|_2 = \sqrt{\sum_i (x_i - w_i)^2} = \sqrt{\sum_i (x_i^2 - 2x_iw_i + w_i^2)}$$

难点1：根号的计算

难点2：向量平方项的计算





汉明距离实现方案1

- 可以处理任意字符串
- 频繁写入 —— 耐久性
- 多步操作 —— 时间

$$L_d = \sum_i xor(x_i, w_i)$$

忆阻器电导 BL输入

基尔霍夫电流输出 WL输入



Lin, Huai, et al. Advanced Materials Technologies 2021.

汉明距离实现方案2



- 某一序列固定
- 翻倍的阵列和输入
- 支持多bit

序列编码方式

XOR

XNOR

$$L_d = \sum_i xor(x_i, w_i)$$




输入序列 (电压)

0 → (0, Vr)
1 → (Vr, 0)

模板序列 (电导)

0 → (Gh, Gl)
1 → (Gl, Gh)

Zhu, Xuan, et al. IEICE Electronics Express 2013.



输入序列 (电压)

(1000, 0100,
0010, 0001)

模板序列 (电导)

(1000, 0100,
0010, 0001)

Kang, Ji-Hoon, et al. Nature Materials 2023.

存算一体化典型算子 – 汉明距离 (查找比对)

查找比对

- 并行性
- 输出简化

$$\sum_i xor(x_i, w_i) = 0 ?$$

查找比对


- 多条序列
- 判断匹配

汉明距离

- 两条序列
- 求和

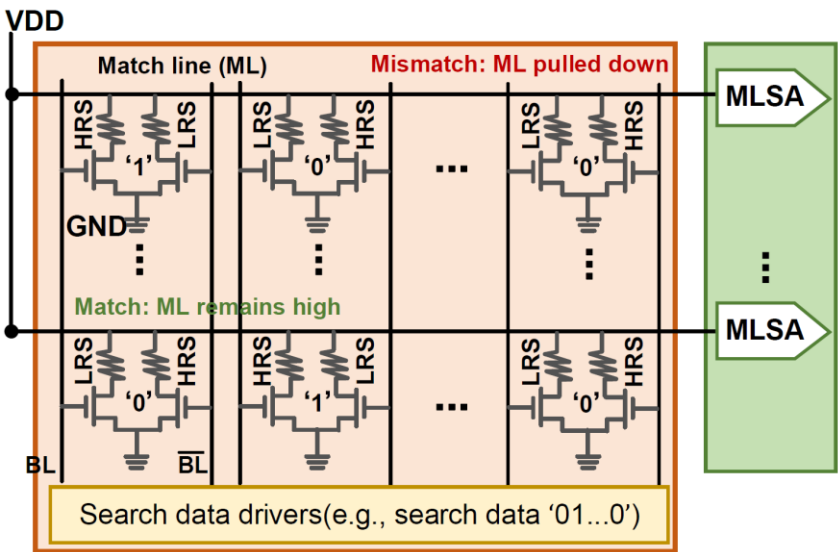
$$xor(x_i, w_i)$$

引入不关心位 X $\rightarrow$ (0, 0) 或 (GI, GI)



Mao, Ruibin, et al. Nature communications 2022.

引入不关心位 X + 输出简化



Liu, Fangxin, et al. DAC 2022.

□ 欧氏距离实现

- 写操作开销过大 → 忽略**输入序列**平方项的计算
- 引入平方计算行 → 进行**模板序列**平方项的计算
- 针对只需比较的特殊情况 → 可忽略**根号**的计算

$$L_2 = \sqrt{\sum_i (x_i - w_i)^2} = \sqrt{\sum_i (x_i^2 - 2x_iw_i + w_i^2)}$$

□ 根据基尔霍夫定律

$$\begin{aligned} I_j &= \sum_i x_i w_{ij} - \frac{M}{2} * \sum_i \frac{(w_{ij})^2}{M} \\ &= \sum_i (x_{ij} w_{ij} - \frac{(w_{ij})^2}{2}) \end{aligned}$$


$$\sum_i \frac{(w_{ij})^2}{M}$$

$$-\frac{M}{2}$$

□ 器件电导被M约束



□ 输入也会受M影响



Jeong, YeonJoo, et al. Nano letters 2018.

□ 欧氏距离优化

- 扩展平方计算行
- 输入更改 + 权重更改

$$L_2 = \sqrt{\sum_i (x_i - w_i)^2} = \sqrt{\sum_i (x_i^2 - 2x_iw_i + w_i^2)}$$

□ 根据基尔霍夫定律

$$\begin{aligned} I_j &= \sum_i x_i w_{ij} - \frac{1}{2} * L * \sum_i \frac{(w_{ij})^2}{L} \\ &= \sum_i (x_{ij} w_{ij} - \frac{(w_{ij})^2}{2}) \end{aligned}$$

$$\sum_i \frac{(w_{ij})^2}{L}$$


□ 器件电导被L约束



□ 输入被约束在正常范围



□ 额外的器件面积





□ 排序：将一组杂乱无章的数据元素，通过一定方法按关键字顺序排列

- 待排序数据存储为器件电导
- WL上的电压映射为数据状态

算法限制速度 $O(NW)$

电路与阵列限制可拓展性



逐位并行读操作实现最小/大值搜索



Prasad, Ananth Krishna, et al. HPCA 2021.

排序优化

- 速度优化 → 更高效的排序算法 $O(N + W)$
- 可拓展性优化 → 三种配置 (阵列规模, 并行性, 多值器件)
- 排序数据固定



存算一体化典型算子 – 生成统计分布

□ 正态分布实现方案1


对于独立并同样分布 (IID) 的随机变量，即使原始变量本身不是正态分布，标准化样本均值的抽样分布也趋向于标准正态分布

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad X \sim N(\mu, \sigma^2)$$

难点1：随机数生成

难点2：支持可控参数

□ 忆阻器读噪声 (C2C随机性)




□ 多器件产生高斯分布 (中心极限定理)

$$f(x) = \frac{1}{2b} \exp\left(-\frac{|x|}{b}\right)$$


$\{X_n\}$ i.i.d

$$\sum_i X_i \sim N(n\mu, n\sigma^2)$$



□ 多值忆阻器

□ 任意分布的中心极限定律



$$\frac{\sum_i (X_i - \mu_i)}{\sqrt{\sum_i \sigma_i^2}} \sim N(0, 1)$$

Lin, Yudeng, et al. Nature Machine Intelligence 2023.

□ 正态分布实现方案2

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$X \sim N(\mu, \sigma^2)$$

难点1: 随机数生成


难点2: 支持可控参数

方案1

方案2



- | | | |
|---------|------|-------|
| □ 单随机数: | 多器件 | 1-2器件 |
| □ 分布: | 一组器件 | 多组器件 |
| □ 采样: | 时间 | 空间 |

□ 忆阻器电导分布 (D2D随机性)



- 多值忆阻器 + 不同忆阻器
- 作差 (正态分布的性质)

$$(G_+ - G_-) \sim N(\mu_+ - \mu_-, \sigma_+^2 + \sigma_-^2)$$



Bonnet, Djohan, et al. Nature communications 2023.

□ 非线性初等函数包括：

■ 幂函数

$$y = x^a$$

■ 指数函数

$$y = a^x$$

■ 对数函数

$$y = \log x$$

■ 三角函数

$$y = \sin x$$

■ 反三角函数

$$y = \arcsin x$$

■ 双曲函数

$$y = \sinh x$$

传统实现方案

□ 数字域

□ $+-\times\div$

□ 泰勒展开

$$y = e^x = 1 + x + \cdots + \frac{x^n}{n!}$$

计算开销很大

□ 秦九韶算法

$$\begin{aligned} y &= a_n x^n + a_{n-1} x^{n-1} + \cdots + a_0 \\ &= ((a_n x + a_{n-1})x + \cdots)x + a_0 \end{aligned}$$

计算开销大

□ 查找表 + 插值

预先计算好，需要从内存中提取
其他值采取对最接近值插值的方式

存储开销大

□ 其他算法：CORDIC, BKM


硬件友好

常用

□ CORDIC算法

■ 基本原理：伪旋转

■ 基本思想：进行很多次伪旋转直到目标角度，每次伪旋转的角度选择方便计算的值得



Zhang, Zihan, et al.
GLSVLSI. 2020.

$$\begin{pmatrix} x_2 \\ y_2 \end{pmatrix} = \cos \theta \begin{pmatrix} 1 & -\tan \theta \\ \tan \theta & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}$$

$$\theta_i = \arctan 2^{-i}, \tan \theta_i = 2^{-i}$$

$$\begin{pmatrix} x_n \\ y_n \end{pmatrix} = \prod_{i=0}^n \cos \theta_i \begin{pmatrix} 1 & -2^i \\ 2^{-i} & 1 \end{pmatrix} \begin{pmatrix} x_0 \\ y_0 \end{pmatrix}$$

$$K = \prod_{i=0}^n \cos \theta_i = 0.607252935 \quad (n \rightarrow +\infty)$$

将 $\tan$ 计算转化
成移位计算

$\tan \theta_i$	θ_i
2^{-0}	45°
2^{-1}	26.565°
2^{-2}	14.036°
2^{-3}	7.1250°
2^{-4}	3.5763°
2^{-5}	1.7899°
2^{-6}	0.8951°

$$\begin{cases} x_{i+1} = x_i - \mu d_i (2^{-i} y_i) \\ y_{i+1} = y_i + d_i (2^{-i} x_i) \\ z_{i+1} = z_i - d_i \theta_i \end{cases}$$

- z_i 实现角度累加
- d_i 控制旋转方向
- μ 选择坐标系


CORDIC算法的忆阻器阵列实现

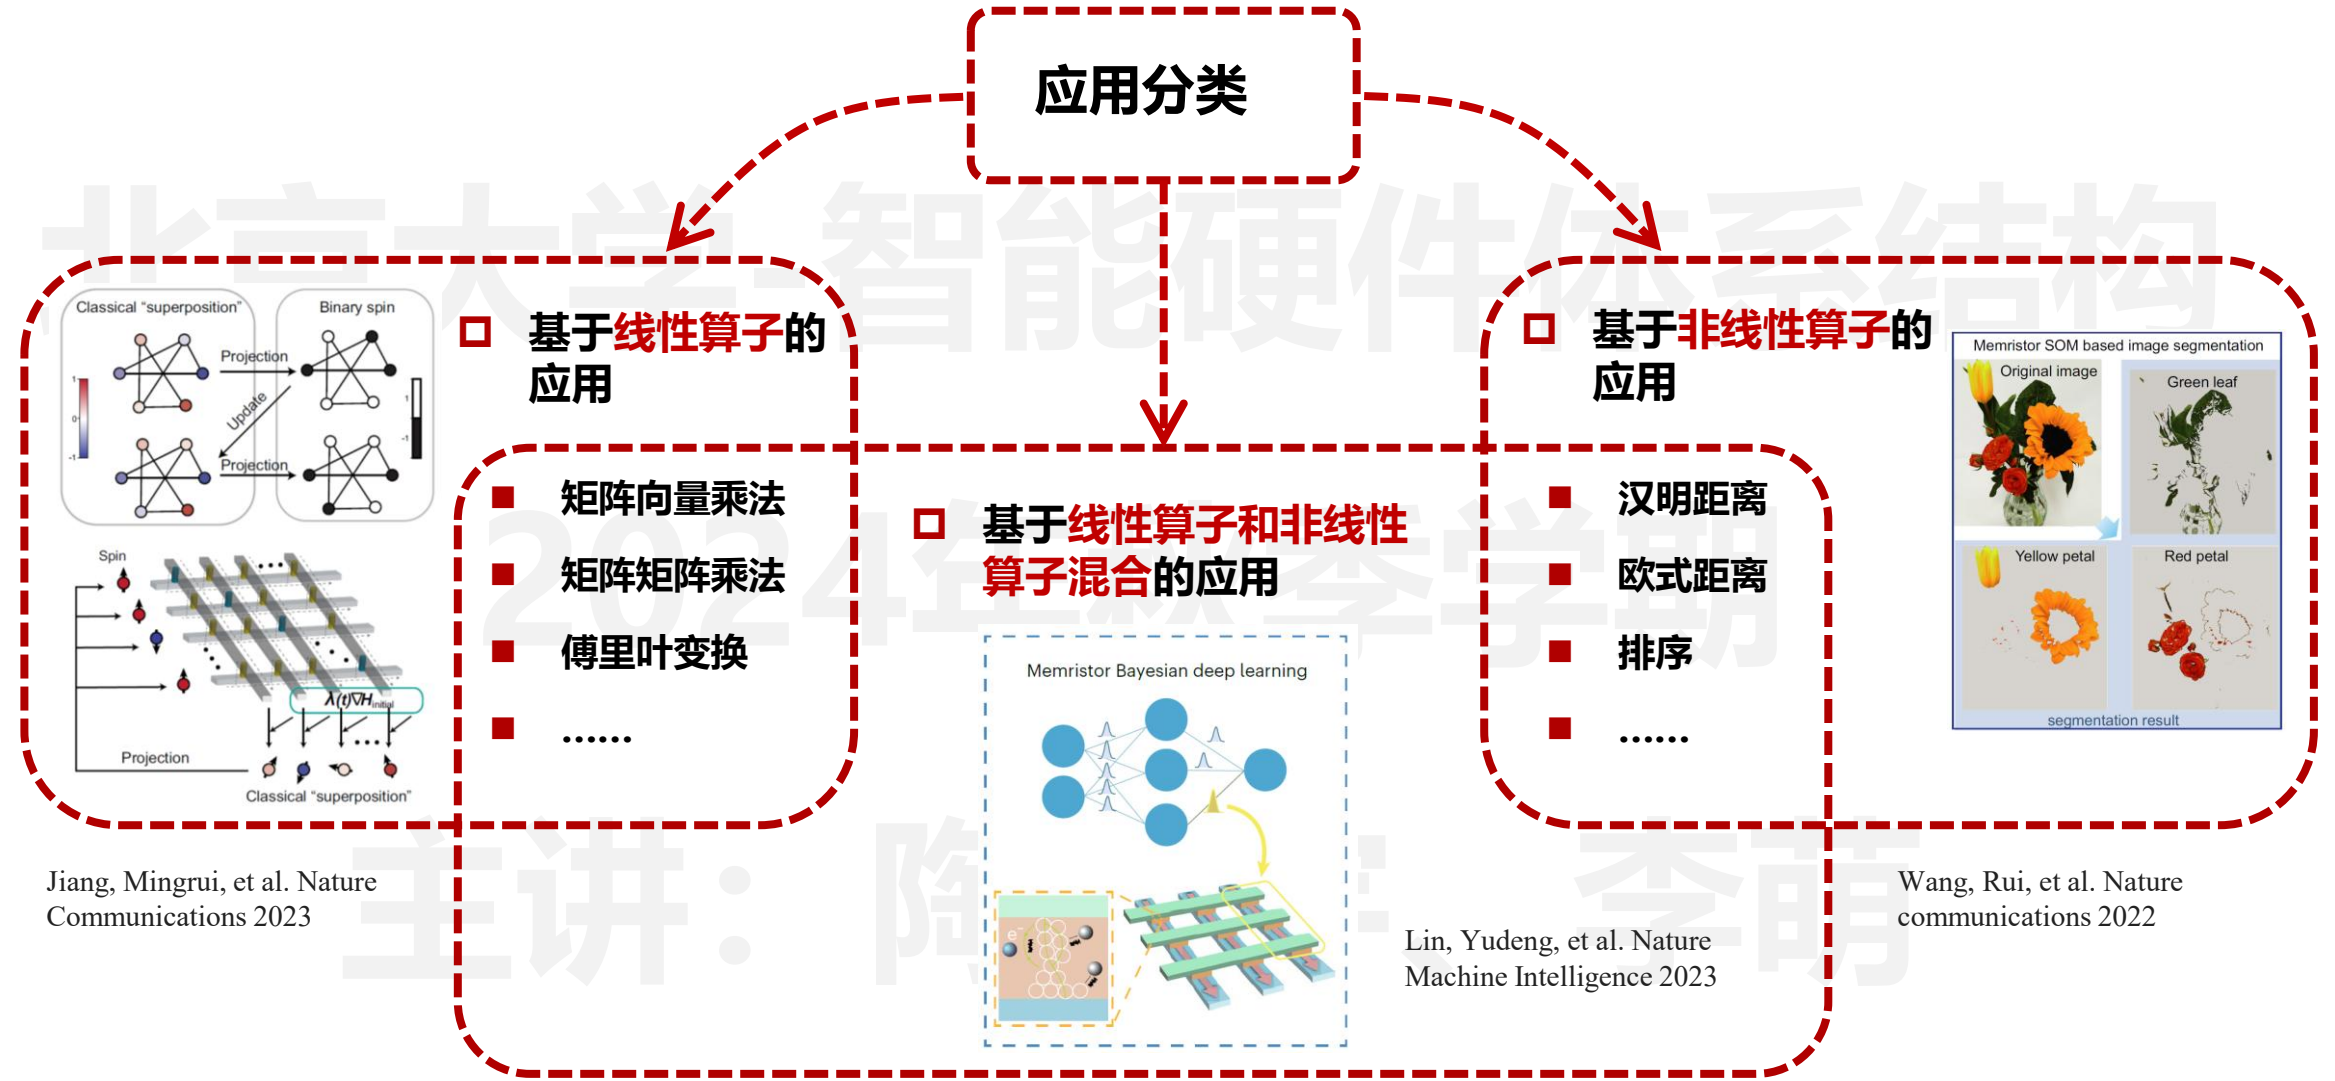
- 稀疏矩阵
- 迭代次数固定
- 计算粒度广，时间长

移位操作适合CMOS电路实现，但是并不适合忆阻器阵列

$$\begin{cases} x_{i+1} = x_i - \mu d_i (2^{-i} y_i) \\ y_{i+1} = y_i + d_i (2^{-i} x_i) \\ z_{i+1} = z_i - d_i \theta_i \end{cases}$$

- z_i 实现角度累加
- d_i 控制旋转方向
- μ 选择坐标系






线性算子：偏微分方程求解

□ 偏微分方程求解（矩阵向量乘法）

- 在数学、物理及工程技术中应用非常广泛，习惯上把这些方程称为数学物理方程
- 使用忆阻器阵列实现矩阵向量乘法，用于雅可比迭代法求解偏微分方程组




Zidan, Mohammed A., et al. Nature Electronics 2018

非线性算子：聚类算法

□ K 均值算法 (欧氏距离)


- 一种无监督算法，旨在将一组向量输入划分为 K 个簇，即对未标记数据集进行预聚类
- 使用忆阻器阵列实现欧氏距离的比较，而无需计算精确值



Jeong, YeonJoo, et al. Nano letters 2018.


自组织映射算法（欧氏距离）

- 一种无监督算法，旨在通过学习输入空间中的数据，生成一个低维、离散的映射
- 使用忆阻器阵列实现欧氏距离的比较，用于寻找最佳匹配单元（BMU）





□ 点云切割 (排序+矩阵向量乘法)

- 对点云进行划分，使得同一划分内的点云拥有相似的特征，可用于分类、部件分割等
- 使用忆阻器阵列实现排序和矩阵向量乘法，用于剪枝和神经网络推理




贝叶斯神经网络（正态分布生成+矩阵向量乘法）

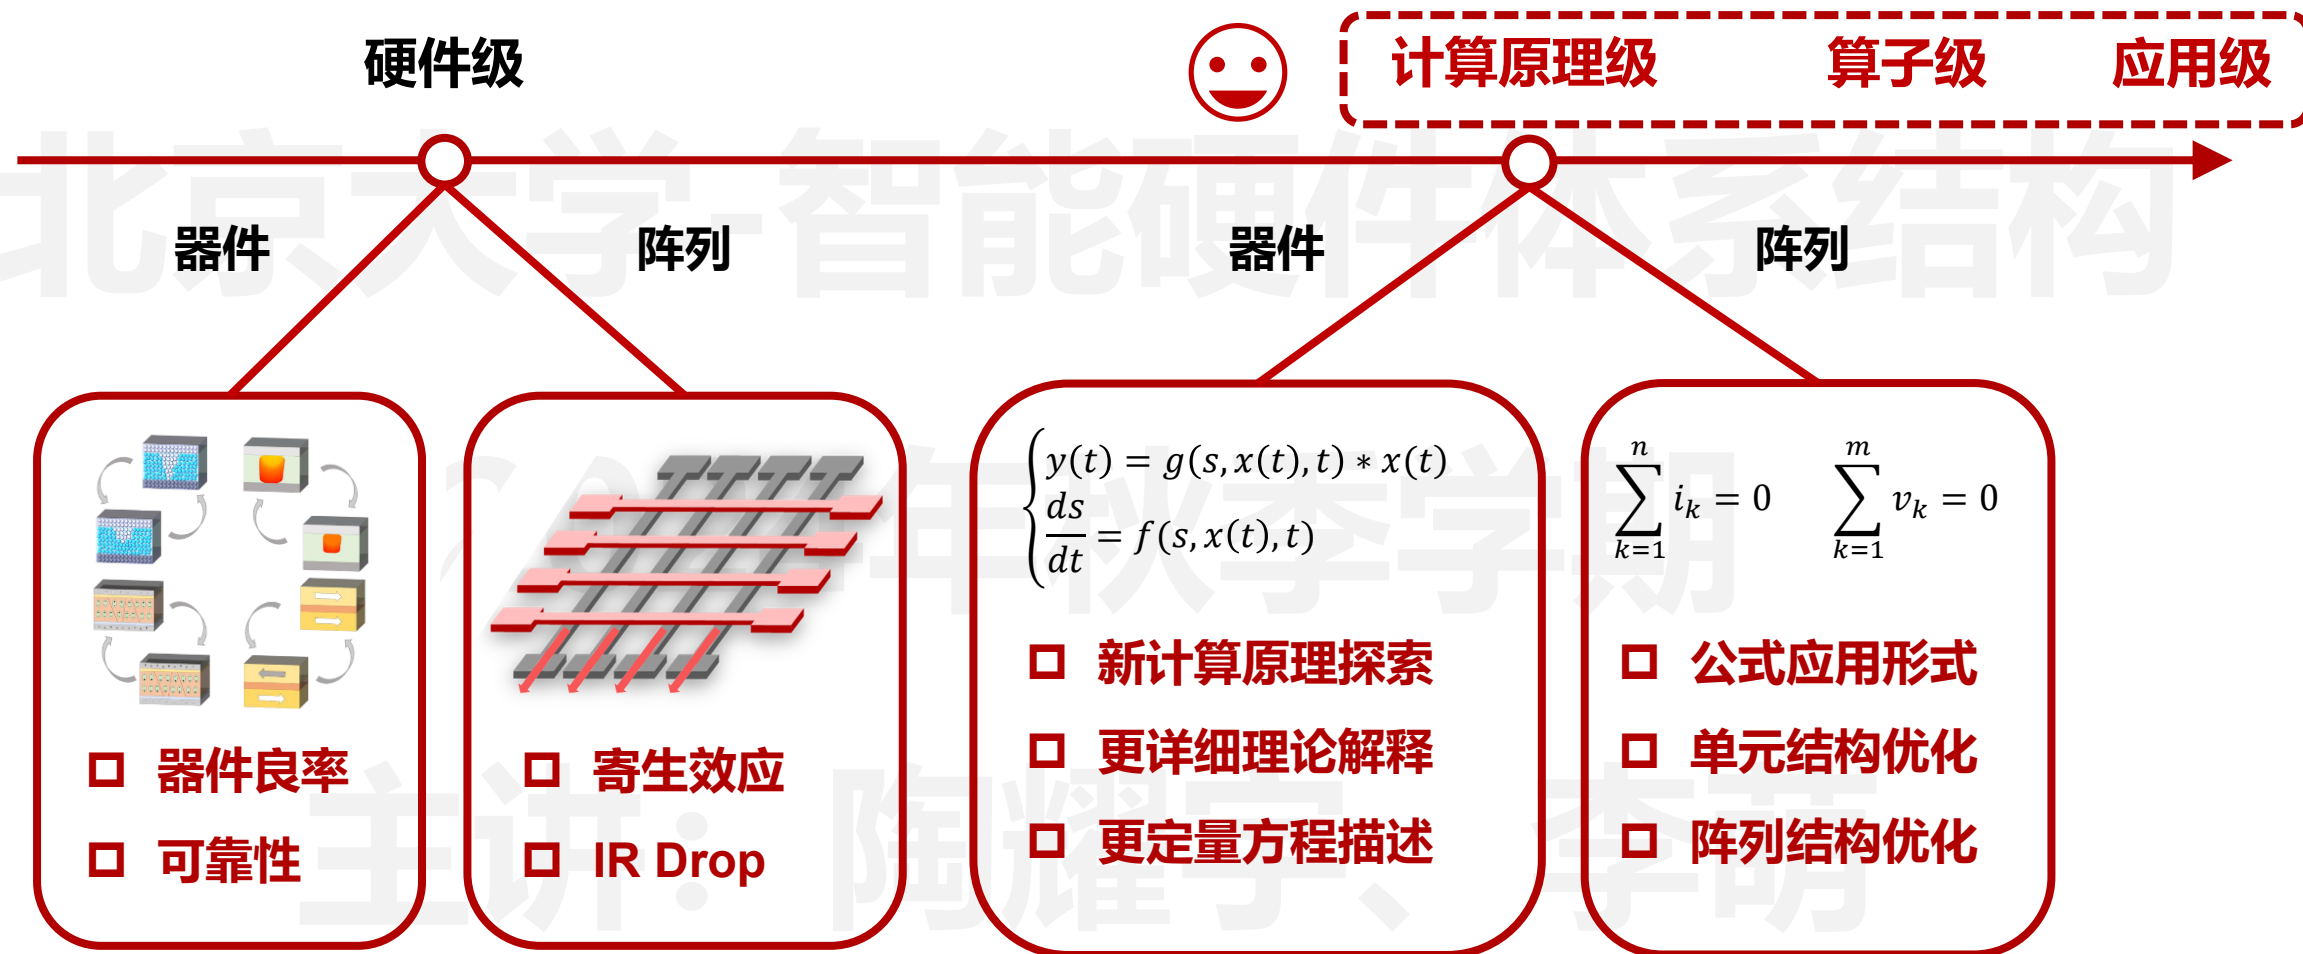
- 权重是一个分布而非定值，可以通过估计合理预测值的区间来表达预测的不确定性
- 使用忆阻器阵列实现正态分布权重和矩阵向量乘法，用于贝叶斯神经网络推理



□ 记忆增强神经网络（汉明距离+矩阵向量乘法）

- 在传统的神经网络模型基础上增加存储模块，用于模拟外部记忆
- 使用忆阻器阵列实现矩阵向量乘法和汉明距离，用于神经网络推理和TCAM





目录


CONTENTS



- 01. 光电异构研究背景**
- 02. 光电异构技术路径**
- 03. 前期研究工作介绍**

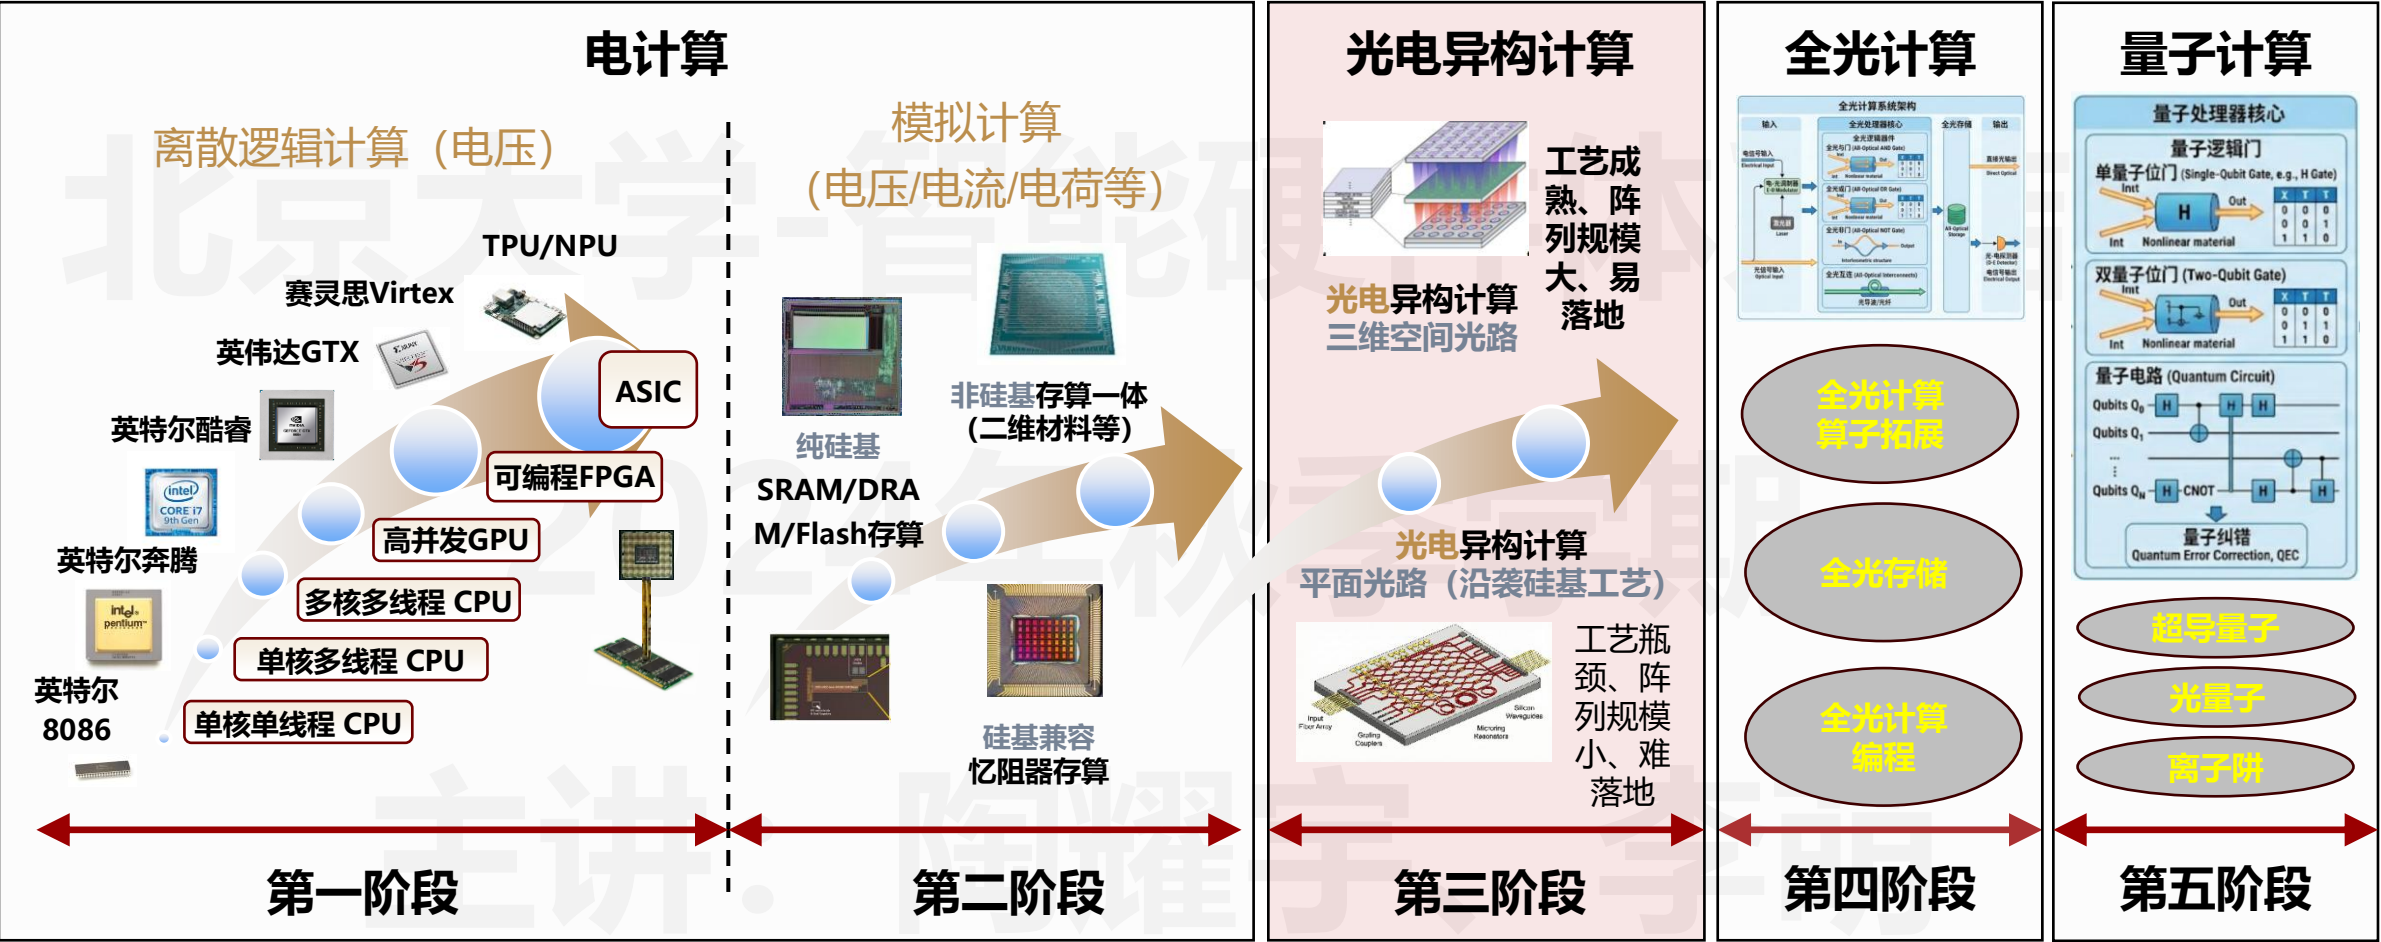
“电” → “光电异构”

- 光相比电的天然优势：有望解决当前系统的延迟、吞吐率、功耗等问题（存储？）



光电异构是未来计算系统的最具潜力的技术路径之一

- 光电异构：既突破电计算瓶颈，又易落地实用



目 录

CONTENTS



- 01. 光电异构研究背景**
- 02. 光电异构技术路径**
- 03. 前期研究工作介绍**


“电” → “光电异构”

- 光电异构的2个层次：光电异构传输（产业发展中）、光电异构计算（学术发展中）

光电异构

光传输/光互联

光计算



输入 Driver 光源 光波导 光电探测 光基带/输出



“电” → “光电异构”





- 光电异构的2个层次：光电异构传输（产业发展中）、光电异构计算（学术发展中）

分类	子类	代表材料	典型器件	主要应用
传输介质	波导 光纤	石英玻璃(SiO ₂)、掺杂石英(掺Ge、F)、 氟化物玻璃、塑料光纤(PMMA)	单模光纤(SMF)、多模光纤(MMF)、保偏光纤、 色散位移光纤、光子晶体光纤	长距离/短距离光信号传输
光源器件	半导体激光器	InGaAsP/InP、GaAs/AlGaAs、InGaAs	DFB激光器、DBR激光器、VCSEL、FP激光器、 可调谐激光器	发射端光信号产生
	发光二极管	GaAs、InGaAsP	LED、SLED(超辐射发光二极管)	短距离、低速传输
光探测器件	光电二极管	InGaAs、Ge、Si、InP	PIN光电二极管、APD(雪崩光电二极管)	接收端光电转换
光调制器件	电光调制	铌酸锂(LiNbO ₃)、InP、硅(Si)、聚合物	MZ调制器、相位调制器、硅光调制器	信号调制(强度/相位)
	电吸收调制	InGaAsP、InGaAlAs	EAM、EML(电吸收调制激光器)	高速直接/外调制
光放大器	掺杂光纤放大	掺铒光纤(EDFA)、掺镨、掺铋光纤	EDFA、PDFA、TDFA	C/L波段信号放大
	半导体/非线性放大	InP基半导体、高非线性光纤	SOA、拉曼放大器(FRA)	放大、波长转换
无源器件	耦合/分路	石英、硅基PLC、熔融拉锥光纤	光分路器、耦合器、环形器、隔离器	光功率分配、方向控制
	波分复用	石英PLC、薄膜滤波片、光纤光栅	AWG、DWDM/CWDM复用器、FBG	波长复用/解复用
	连接/开关	陶瓷插芯(ZrO ₂)、MEMS、液晶、硅光	光连接器、MEMS光开关、WSS	链路连接、路由交换
集成光子	光子集成芯片	硅(SOI)、InP、氮化硅(Si ₃ N ₄)、 铌酸锂薄膜(TFLN)	硅光收发芯片、InP PIC、LNOI调制器	高速相干通信、数据中心光模块
光模块	封装器件	上述材料集成	SFP/SFP+/QSFP/QSFP-DD/OSFP、CFP系列	10G–800G/1.6T光收发


“电” → “光电异构”

- 光电异构的2个层次：光电异构传输（产业发展中）、光电异构计算（学术发展中）

是否能在光链路进行部分计算
减轻电芯片计算负载？




传统光模块




硅光光模块

典型硅光模块的构成 (来源: IMEC)




“电” → “光电异构”


- 光电异构的2个层次：光电异构传输（产业发展中）、光电异构计算（学术发展中）




硅光光模块的封装构造



不同材料的波导弯曲半径对比



硅波导结构



- 耦合对准难
 - 亚微米级对准精度要求导致极高
- 热管理冲突
 - 光器件难以耐受电芯片密集热流
- 光源集成困境
 - 激光器寿命短板导致内置维护难
- 光纤管理拥堵
 - 高通道数导致物理空间受限
- 测试良率风险
 - 缺乏晶圆级光电融合测试手段


典型硅光模块的集成工艺与CPO光电共封（来源：IMEC）

“电” → “光电异构”


- 光电异构的2个层次：光电异构传输（产业发展中）、光电异构计算（学术发展中）

光电异构

光传输/光互联




光计算



从“电” → “光电异构”

- 光计算相比电的天然优势：解决当前系统的延迟、功耗等问题

英伟达智能芯片产品进化史（2020-2026）



大幅度优化首个token延迟与精度能效积必须解决的“两面墙”问题

- **延迟墙+精度能效墙**：电计算带来延迟瓶颈，高精度算力伴随着高功耗
- 思想自由 兼容并包

■ 电计算：延迟受载流子（电子/空穴）传输的速度物理限制


- **晶体管**：硅中电子物理上限饱和速度 $\sim 10^7$ cm/s，难以提升
- **互连线**：电阻 $\times$ 电容乘积，比晶体管延迟大（尤其先进制程）
- 芯片尺寸越大，信号传播延迟越来越成为不可忽视的瓶颈

■ 电计算：功耗受载流子与硅基材料本体碰撞产生的热耗散限制

- **动态功耗**： $P = \alpha CV^2f$ （每次计算晶体管充放电能量）
- **静态漏电流**：量子隧穿效应（在 $< 5\text{nm}$ 制程下愈发严重）
- **导线热耗散**：由导线的电阻引起，即 $P = I^2R$

光电异构现状 – 光计算

- 光相比电具有多重天然优势：波粒二象性等



- 光经典计算利用**光的波动性**，包括**衍射、干涉、折射等**，基于**各类衍射器件、马赫-曾德尔干涉仪 (MZI)、微环谐振器件 (MRR)** 等

- 离散逻辑光计算**是借鉴数字电路计算机概念实现**数字光学计算**，如**光学晶体管、光学逻辑器件**、时空编码、三值光计算机等，基于光学逻辑门的数字光计算并没有被验证为是一种实际有效的计算架构




- 非离散逻辑光计算**则是从**光学角度出发基于多维光场信号调制实现某种专用光学处理**，如**乘加运算、卷积、微分/积分、傅里叶变换、光学神经网络**等

利用单个光子作为量子比特 (qubit) 的载体，通过光子的量子特性来执行计算
思想自由 兼容并包


光电异构现状 – 光计算

- 光相比电具有多重天然优势：波动性等

利用光计算构建AND、OR等逻辑单元，进而完成复杂计算



• 非离散逻辑波动光计算




与电存算一体类似，当前光计算主要聚焦线性矩阵计算，光电异构架构成为近期支持AI大模型等的可行路径

技术路线1：基于光学干涉 – 基于干涉原理的乘累加


马赫-曾德尔干涉仪 (MZI)

一束光输入此结构，外加电压可改变光相位实现调制



$$E_{out} = \frac{E_{in}}{2} \left(e^{j\frac{\pi V_1}{2V_\pi}} + e^{-j\frac{\pi V_1}{2V_\pi}} \right) = E_{in} \cos\left(\frac{\pi V_1}{2V_\pi}\right)$$



$$E_{out} = \frac{E_{in}}{2} \left((1+k)e^{j\frac{\pi V_1}{2V_\pi}} + (1-k)e^{-j\frac{\pi V_1}{2V_\pi}} \right) = \frac{E_{in}}{2} \left(e^{j\frac{\pi V_1}{2V_\pi}} + e^{-j\frac{\pi V_1}{2V_\pi}} + ke^{j\frac{\pi V_1}{2V_\pi}} - ke^{-j\frac{\pi V_1}{2V_\pi}} \right) \\ = E_{in} \left(\cos\left(\frac{\pi V_1}{2V_\pi}\right) - jk \sin\left(\frac{\pi V_1}{2V_\pi}\right) \right)$$



- MZI干涉结构无法直接实现任意规模的权重矩阵 W ，需要先将其进行矩阵奇异值分解，即 $W=U\Sigma V^*$ ，其中 W 为任意的 $m \times n$ 矩阵， U 为 $m \times m$ 的酉矩阵， Σ 为 $m \times n$ 的对角矩阵，对角线上的值为非负实数， V 为 $n \times n$ 的酉矩阵， V^* 表示 V 的共轭矩阵
- 通过MZI拓扑级联的方式实现酉矩阵 U 和 V^* ，并采用可调波导实现对角矩阵 Σ



光电异构现状 – 光计算

- 技术路线1：基于光学干涉 – 多级拓扑互连MZI结构





技术劣势：制造误差、对齐误差、多级集成尺寸过大

• 技术路线1：基于光学干涉 – 多级拓扑互连MZI结构



技术劣势：制造误差、对齐误差、多级集成尺寸过大

技术路线1：基于光学干涉 – 多级拓扑互连MZI结构 – 训练+推理




Single-chip photonic deep neural network with forward-only training, Nature Photonics, 2025


技术路线1：基于光学干涉 – MZI结构交叉阵列

MZI结构交叉阵列原理：

$$y = Wx; y_i = \sum_j W_{ij}x_j;$$
$$\begin{pmatrix} E_{out1} \\ E_{out2} \end{pmatrix} = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 & j \\ j & 1 \end{pmatrix} \begin{pmatrix} e^{-j\Delta\phi} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 \\ \sqrt{2}/2 \end{pmatrix} x$$
$$W_{ij}x = |E_{out1}|^2 - |E_{out2}|^2 = \left(2 \cos^2 \left(\frac{\Delta\phi + \phi_b}{2} \right) - 1 \right) x,$$



Lightening-Transformer: A Dynamically-operated Optically-interconnected Photonic Transformer Accelerator



SCATTER: Algorithm-Circuit Co-Sparse Photonic Accelerator with Thermal-Tolerant, Power-Efficient In-situ Light Redistribution

技术路线2：基于光学相位调制 – 微环光路结构

Micro Ring



器件原理：不同微环半径可调制相位，光电探测光强与相位相关

$$O = XI = \begin{bmatrix} 1 - 2a_{11} & 1 - 2a_{12} & 1 - 2a_{13} & 1 - 2a_{14} \\ 1 - 2a_{21} & 1 - 2a_{22} & 1 - 2a_{23} & 1 - 2a_{24} \\ 1 - 2a_{31} & 1 - 2a_{32} & 1 - 2a_{33} & 1 - 2a_{34} \\ 1 - 2a_{41} & 1 - 2a_{42} & 1 - 2a_{43} & 1 - 2a_{44} \end{bmatrix} \begin{bmatrix} i_1 \\ i_2 \\ i_3 \\ i_4 \end{bmatrix}$$

技术劣势：



- 调制时的非线性
- 混合时候的非线性
- 随温度波动
- 微缩困难

Intensity Modulator




A small microring array that performs large complex-valued matrix-vector multiplication

技术路线2：基于光学相位调制 – 微环光路结构



• 技术路线2：基于光学相位调制 – 微环光路结构



微环的最大问题：一致性、集成度、可微缩行

技术路线3：基于片上光强叠加 – 相变器件交叉阵列（牛津大学、上海光本位科技）

基于相变器件PCM

器件原理：

- 倏逝耦合（evanescent coupling）
- PCM器件吸收一部分光，改变光强完成乘法

技术劣势：



- 分光过程并非均匀distribute
- PCM器件的非理想性（漂移、一致性）
- 需要高精度波导，微缩困难

Kernel matrix Input Output


$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} \times \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_m \end{bmatrix} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

Kernel 1 Kernel n

$$Y_n = X_1 a_{1n} + X_2 a_{2n} + \dots + X_m a_{mn}$$




技术路线3：基于片上光叠加 – 硅光器件阵列 (MIT Dirk Englund、曦智科技)



复用硅光互联机制，在片上光路添加叠加功能（当前达到128x128集成规模）



（落地路径较为清晰，但性能受限于阵列规模、波导微缩困难、大规模集成一致性等问题）

- 技术路线3：基于片上光叠加 – 硅光器件阵列 (MIT Dirk Englund、曦智科技)



- PACE的核心是**64x64的光学矩阵乘法器**，由**一块集成硅光芯片**和**一块CMOS微电子芯片**以**3D封装形式堆叠而成**
- PACE的单个光子芯片中集成超过10000个光子器件，运行1GHz系统时钟
- 运行特定神经网络算法的速度可达目前高端GPU的数百倍
- 输入向量值首先从片上存储中提取，**由数模转换器转换为模拟值**，通过电子芯片和光子芯片之间的微凸点应用于相应的光调制器，**形成输入光矢量**
- 输入光矢量通过光矩阵传播，产生输出光矢量，并达到一组光电探测器阵列**，从而将光强转换为电流信号
- 最后，电信号通过微凸点返回到电子芯片，通过跨阻放大器和模数转换器返回数字域

- 技术路线3：基于片上光叠加 – 硅光器件阵列（MIT Dirk Englund、曦智科技）




高带宽、低功耗、低延迟、距离不敏感




通用性强，可将不同类型的电子芯片与之结合，为芯片间提供高速、低功耗的互连




有利于任何有高带宽需求的应用场景



光芯片实际图片




封装实际图片




广播延时	1ns
最长广播距离	50mm
通道数	512ch
单通道频率	4GHz
片上总带宽	2Tbps

*首个芯片实测数据，未来提升空间巨大




机架之间互连

低延时、长距离、低功耗



假设 AWG26 线缆, PCIe 5.0 信号





32 根直径 > 6mm (CAT8) 线缆 16 根直径 = 0.125mm 光纤

铜线缆勉强支持相邻服务器间CXL扩展

• 技术路线4：基于空间光学衍射 – 衍射光斑乘累加


当遇到障碍物或小孔时，光会偏离直线传播路径，产生光强分布不均匀的现象，这就是**衍射**。光的衍射可以根据**惠更斯-菲涅耳原理**进行描述，即波前的每一点可分解为沿波前法向量传播的次波，这些次波向前传播并相互干涉，相互叠加形成新的波前。通过对衍射层的结构进行优化设计后，可以对输入光场的振幅和相位进行调制，在下一层实现特定的光场分布，从而实现线性矩阵计算。



Diffraction of a single slit




单缝衍射



一般孔径衍射




圆孔的衍射花样



圆屏的衍射花样

- 技术路线4：基于空间光学衍射 – 多层衍射掩膜版（算子受限，和存算一体类似）




器件原理:

- 3D打印掩模版，每个 pixel 厚度不同
- 透过光的相位和厚度有关


技术劣势:

- 制造误差、对齐误差
- 结构固定、无法重构



All-optical machine learning using diffractive deep neural networks, UCLA 2018

• 技术路线4：基于空间光学衍射 – 多层衍射掩膜版+电数字/模拟芯片（算子扩展）



IC: 信息编码 (电)

DM: 光学衍射调制 (电-光)


DC: 光学衍射光路 (光)

OS: 衍射光场叠加 (光-电)

CA: 激活函数计算 (电)

Large-scale neuromorphic optoelectronic computing with a reconfigurable diffractive processing unit. Nature Photonics, 2021

• 技术路线4：基于空间光学衍射 – 多层衍射掩膜版+电SRAM模拟存算芯片（算子扩展）




- ACCEL结合了衍射光学计算 (OAC) 和电子模拟计算 (EAC)
- ACCEL利用OAC进行特征提取，然后将光诱导的光电流直接用于集成模拟计算芯片中的进一步计算
- 无模数转换器 (ADC)，每帧的计算延迟降低到72ns


All-analog photoelectronic chip for high-speed vision tasks. Nature, 2023

- 技术路线4：基于空间光学衍射 – 多层衍射掩膜版 (Microsoft)


a



b







c




Analog optical computer for AI inference and combinatorial optimization, Nature, 2025

- 技术路线4：基于空间光学衍射 – 多层衍射掩膜版 (Microsoft)





Analog optical computer for AI inference and combinatorial optimization, Nature, 2025

- 技术路线5：基于空间光学叠加 – 三五族VCSEL、microLED、各类空间光源阵列等



构建可叠加的垂直三维光路完成矩阵乘加操作
(阵列规模大是核心优势，仍存在空间光路尺寸微缩等问题)

光计算技术总结



光计算产业现状

公司/团队	国别	成立	技术路线	进展
Lightmatter	美国	2017	硅光矩阵乘法 + Passage光互连	D轮4亿美元，估值44亿美元
Lightelligence (曦智科技)	美国/中国	2017	光子处理器 PACE / Hummingbird	MIT背景，估值超20亿美元
Luminous Computing	美国	2018	大规模光子AI超算	比尔·盖茨投资，瞄准LLM训练
Salience Labs	英国/美国	2021	多波长光子张量核	牛津+明斯特大学衍生
Q.ANT	德国	2018	薄膜铌酸锂(TFLN) 光子NPU	2025年推出商用光子AI加速卡
NTT	日本	—	光神经网络/IOWN 全光网络	国家级全光计算计划
Optalysys	英国	2013	傅里叶光学计算	面向AI与全同态加密
曦智科技 (中国主体)	中国	2017	光电混合计算卡 PACE	上海，已部署系统
光子算数	中国	2017	光子AI芯片	清华背景
光本位科技	中国	2022	存算一体光子芯片	上海，相变材料路线
清华"太极/太极-II"团队	中国	2024	全光AI芯片	《自然》论文，能效超H100，首款大规模光训练芯片
上海交大邹卫文团队	中国	—	光子张量处理芯片	20GHz张量卷积，588 GOPS/mm²
中科院上海光机所 (moqi等)	中国	—	光子计算原型机	学术产业化
图灵量子 (光智能业务线)	中国	2021	光子智能计算芯片	上海交大金贤敏团队

公司/团队	国别	成立	技术路线	进展
PsiQuantum	美国	2016	硅基光子容错量子计算	估值超60亿美元，2025年获NVIDIA 10亿美元融资，目标百万量子比特
Xanadu	加拿大	2016	连续变量光量子 (CV)	推出Borealis光量子机，与Rolls-Royce合作
ORCA Computing	英国	2019	光子量子+AI混合，量子记忆	已交付多台系统给英国国防部
QuiX Quantum	荷兰	2019	光子量子处理器 (线性光学)	欧洲领先光量子硬件供应商
Quandela	法国	2017	单光子源光量子计算	推出Ascella云量子机
TundraSystems Global	英国	—	光量子计算芯片	早期阶段
NTT (相干伊辛机)	日本	—	相干伊辛机 (光学退火)	介于经典/量子之间，组合优化求解
图灵量子 (TuringQ)	中国	2021	光量子+光子智能	上海交大金贤敏团队，"天工"系列芯片
玻色量子	中国	2020	相干光量子计算机/相干伊辛机	北京，已发布"天工量子大脑"
中科大潘建伟团队 (产业化: 国盾量子相关)	中国	—	"九章"系列光量子原型机	高斯玻色采样里程碑，学术领先
太init (启科量子光子线)	中国	—	光量子探索	早期